

Análisis del sistema ECOBICI

CIUDAD DE MÉXICO 2024-2026



43.6M

VIAJES EN DATASET

100K

MUESTRA DEL TRABAJO

9

MÉTODOS APLICADOS

689

ESTACIONES ECOBICI



ALINA CARÍAS (22539) Y ARIELA MISHAAN (22052)

Descripción del sistema y datos



¿QUÉ ES ECOBICI?

Sistema público de bicicletas de la CDMX operado por SEMOVI desde 2010.


- 689 estaciones * 3 alcaldías
- 9,300 bicicletas
- 70,000 viajes/día entre semana




DATASET CSV MENSUALES

- 9 variables originales: género, edad, ID bici, estación retiro/arribo, fecha+hora retiro/arribo
- Variables derivadas: duracion_min, es_circular, lat/lon (API GBFS), is_weekend, genero_M
- Limpieza: se eliminaron viajes con duración de 0 a 180min
- Muestra de trabajo: 100,000 viajes

Exploración: patrones temporales

- Pico AM: 7–9h – Pico PM: 17–19h
- Patrón bimodal solo lunes–viernes
- Fin de semana: menos viajes, mayor duración promedio
- ECOBICI = transporte de “última milla”








Exploración: distribuciones

- ~9min / mediana de viaje
- 69% / usuarios masculinos
- 25-40 años / rango de edad más frecuente
- Asimetría positiva en duración → mayoría de viajes son cortos



Exploración: estaciones



Pocas estaciones concentran la mayoría de los viajes
Mayor densidad al centro del mapa (IA: corredor Reforma-Insurgentes)

Selección de variables

Se aplicaron 3 algoritmos para selección de variables: correlación de Pearson, información mutua, Lasso.

Variable objetivo: duración.



PEARSON

Ningún par supera $|r| > 0.3 \rightarrow$ Sin multicolinealidad, se observan todas.



MUTUAL INFORMATION

Variables con MI > 0.01 : **lon** (0.023) * **lat** (0.021) * **es_circular** (0.011)
 $\rightarrow$ Geografía lidera



LASSO

$\alpha = 1 \rightarrow$ solo **es_circular** sobrevive
Alphas menores: variables geográficas
 $\rightarrow$ 8 features finales para el modelado

Metodología

100k Viajes, StandardScale

Para algunos se usó submuestra por complejidad computacional.



SUPERVISADO

- Regresión OLS/Risge/LASSO/EN:
Comparación para predicción de `duracion_min`.

REDUCCIÓN DE DIM

- PCA: sobre las 8 vars.
- NMF: factorización de matriz de 4 variables, K elegido por codo en RMSE de reconstrucción.
- t-SNE: Proyección de 500 puntos a 2D

CLUSTERING

- K-Means: evaluado para $K=2-10$
- Jerárquico: linkage Ward
- Cluster espectral: $k = 15$
- GMM y EM: K de 2-8, min. BIC
- KNN: clasificación de género

DENSIDAD




- KDE: estimación de densidad de `duracion_min`. Bandwidth: validación cruzada.

PCA



CP	% VAR	Qué captura
CP1	14.8%	Posición geográfica
CP2	13.5%	Patrón temporal
7 CPs	80%	–


Alta dimensión intrínseca: no reducible a 2D sin pérdida importante




K-Means

●●●●● Sillhouette = 0.151, D-B = 1.900 → separación moderada

Cluster	Duración	Género	Circular
C0	14.95 min	100% F	No
C1	8.88 min	100% M	No
C2	11.03 min	Mixto	No
C3	6.13 min	65% M	Sí







Variables temporales (hora, mes), geográficas: casi idénticas para todos los clusters. También se probó clustering jerárquico, espectral.



Clustering comparado

●●●●● ARI K-Mean vs Jerárquico = 0.356 → estructura similar, fronteras difusas


Método	K	Silhouette
K-Means	4	0.151
Jerárquico	4	0.134
GMM + EM	8	-(certeza 0.916)
Spectral	4	0.135



KNN

● ● ● ● ● Análisis de géneros.

Clase	Recall	F1
F	0.05	0.08
M	0.96	0.82



- Desequilibrio de clases
- Accuracy = 0.70 = línea base del clasificador mayoritario
- El modelo no aporta capacidad discriminativa real



Regresión



Modelo	R^2	RMSE
OLS	0.014	10.95 min
Ridge	0.014	10.95 min
LASSO	0.014	10.95 min
ElasticNet	0.014	10.95 min

Se compararon OLS, Ridge, Lasso, ElasticNet para predecir duracion_min. Penalización de coeficientes no mostró mejora.


- Coeficiente más grande: es_circular
- Otros importantes: longitud y latitud
- Todos los métodos asignan pesos casi idénticos.

- Los 4 modelos similares → subajuste, no sobreajuste
- Se necesitan más variables de ruta para mejorar



Estimación de densidades por kernels

●●●●● Se estimó la densidad de duracion_min




- Bandwidth óptimo: validación cruzada
- Distribución unimodal – duración alrededor de 7 min
- No varía por género.




Manifold Learning (*t-SNE*)

●●●●● Por complejidad: muestra de 5000 puntos.



- Estructura Clusters 1 y 2 se traslapan, 0 y 3 bien separados
- Duración de viaje no aporta en la proyección.



Discusión de resultados

3 hipótesis iniciales:

1. Uso laboral con picos en horas pico
2. Grupos diferenciados entre los viajes según features
3. Predictibilidad de la duración de los viajes



- Distribución bimodal diaria (picos en horario laboral)
- Todos los clusters comparten horarios y geografía



- Cuatro métodos de clustering con métricas similares
- Grupos no bien separados (silueta baja)
- Distinción más clara: viajes circulares y el resto.



- Combinación de features utilizadas no predicen duración
- Subajuste, más variables necesarias
- Geografía tiene el mayor impacto

Conclusiones



Para investigaciones futuras:

- Incorporar par origen-destino como variable
- Explorar modelos no lineales (Random Forest, XGBoost) para predecir duración
- Analizar evolución temporal de los clusters

ECOBICI opera como transporte “de última milla”

- viajes cortos para iniciar/terminar trayecto
- Distribución bimodal diaria en horario laboral
- Mediana de 9 min

4 grupos de viaje identificables, pero con separación no tan clara.

- Separación principal: género y duración, no variables geográficas.

- Duración del viaje no predecible con variables disponibles.
- Patrones de uso no cambian por género
- Variables geográficas junto a es_circular son las más informativas del conjunto.

Referencias



- [1] Wikipedia, "Ecobici (Ciudad de México)," 2025. [En línea]. Disponible: <https://es.wikipedia.org/wiki/Ecobici>
- [2] ECOBICI/SEMOVI, "Datos abiertos del Sistema ECOBICI," 2026. [En línea]. <https://ecobici.cdmx.gob.mx/datos-abiertos/>
- [3] I. T. Jolliffe, Principal Component Analysis, 2nd ed. New York: Springer, 2002, pp. 1–30.
- [4] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.
- [5] A. P. Dempster, N. M. Laird y D. B. Rubin, "Maximum likelihood from incomplete data via the EM algorithm," J. Royal Statistical Society B, vol. 39, no. 1, pp. 1–38, 1977.
- [6] A. Y. Ng, M. I. Jordan y Y. Weiss, "On spectral clustering: Analysis and an algorithm," en Advances in Neural Information Processing Systems, vol. 14, 2001.
- [7] T. Cover y P. Hart, "Nearest neighbor pattern classification," IEEE Trans. Information Theory, vol. 13, no. 1, pp. 21–27, 1967.
- [8] R. Tibshirani, "Regression shrinkage and selection via the Lasso," J. Royal Statistical Society B, vol. 58, no. 1, pp. 267–288, 1996.
- [9] B. W. Silverman, Density Estimation for Statistics and Data Analysis. London: Chapman & Hall, 1986, ch. 3.
- [10] L. van der Maaten y G. Hinton, "Visualizing data using t-SNE," J. Machine Learning Research, vol. 9, pp. 2579–2605, 2008.
- [11] S. T. Roweis y L. K. Saul, "Nonlinear dimensionality reduction by locally linear embedding," Science, vol. 290, no. 5500, pp. 2323–2326, 2000.
- [12] D. D. Lee y H. S. Seung, "Learning the parts of objects by non-negative matrix factorization," Nature, vol. 401, pp. 788–791, 1999.
- [13] GeeksforGeeks. (2025, 13 septiembre). Feature Importance in PCA: Analyzing Loadings and Biplots. GeeksforGeeks. 3 hipótesis iniciales: